

Poluicao Luminosa na Costa de Santa Catarina: um Pipeline de Processamento de Imagem para Estimar Risco Ecologico Relativo

Pedro Pacheco¹, Carlos Soler¹

Universidade Regional de Blumenau (FURB)
Disciplina de Processamento de Imagem

Abstract

This paper presents an image-processing workflow for investigating artificial night light near aquatic environments on the coast of Santa Catarina, Brazil. The study focuses on Florianopolis, Balneario Camboriu and Itajai. Instead of training a supervised neural network, the work implements a deterministic classification pipeline that combines water segmentation, VIIRS night-light layers, marine buffers, productivity proxies, fauna sensitivity and protected-area overlays. The output is a relative ecological-risk index designed for comparison between cities and for visual interpretation in an image-processing course context.

Resumo

Este artigo apresenta um fluxo de processamento de imagem para investigar a presença de luz artificial noturna proxima a ambientes aquaticos na costa de Santa Catarina. O estudo considera Florianopolis, Balneario Camboriu e Itajai. Em vez de treinar uma rede neural supervisionada, foi implementado um classificador deterministico que combina segmentacao de agua, camadas de luz noturna VIIRS, buffers marinhos, proxies de produtividade, sensibilidade de fauna e sobreposicao com unidades de conservacao. O resultado e um indice ecologico relativo, voltado a comparacao entre cidades e a interpretacao visual dentro do contexto da disciplina de Processamento de Imagem.

1 Introducao

A luz artificial noturna e um indicador visual de urbanizacao, infraestrutura, portos, turismo e ocupacao costeira. Em regioes litoraneas, essa iluminacao pode alcancar praias, rios, canais, estuarios e baiais, alterando condicoes naturais de orientacao, alimentacao, reproducao e migracao de organismos aquaticos e costeiros. O problema e especialmente relevante em areas urbanizadas de Santa Catarina, onde cidades costeiras combinam crescimento urbano, atividades portuarias e intensa ocupacao turistica.

O objetivo deste trabalho e desenvolver um pipeline de processamento de imagem capaz de identificar e comparar a exposicao luminosa sobre areas de agua em Florianopolis, Balneario Camboriu e Itajai. A partir dessa exposicao, o trabalho constroi uma camada adicional de risco ecologico relativo. O indice nao pretende provar impacto biologico direto; seu papel e organizar evidencias espaciais em uma escala comparavel, permitindo

discutir onde luz, água, produtividade, sensibilidade de fauna e unidades de conservação coincidem.

A proposta foi implementada como uma arquitetura modular de classificação por imagem. Embora o enunciado da atividade mencionasse TensorFlow, Keras ou scikit-learn, a base disponível não possuía rótulos supervisionados confiáveis para treinamento de uma rede neural. Por isso, adotou-se uma abordagem determinística, auditável e coerente com sensoriamento remoto: segmentação por índice espectral, normalização de radiancia, classificação por buffers e combinação ponderada de camadas ambientais.

2 Desenvolvimento e Descrição do Problema

2.1 Problema a ser resolvido

O problema pode ser descrito como uma classificação espacial: dado um conjunto de imagens e camadas derivadas, identificar regiões aquáticas que estão próximas de luz artificial noturna e estimar um risco relativo para ambientes costeiros. A pergunta central é: entre as cidades analisadas, onde a iluminação artificial se sobrepõe à água costeira e a proxies de sensibilidade ecológica?

A saída esperada não é uma classe biológica absoluta, mas uma representação comparável entre cidades. O índice final combina exposição luminosa, presença/sensibilidade de fauna, produtividade primária e habitat raso:

$$\text{risco} = \text{luz_fundo} \times \text{habitat} \times \text{fauna}$$

Essa equação foi implementada em escala normalizada entre 0 e 1. Valores mais altos indicam maior coincidência espacial entre luz artificial, água rasa/produzida e grupos biológicos sensíveis.

2.2 Montagem da base

A base foi montada a partir de imagens de referência diurnas e noturnas, máscaras de água, mapas de radiancia sobre água e camadas ambientais derivadas. As três cidades foram processadas de forma padronizada, mantendo o mesmo raio de recorte e a mesma lógica de geração de imagens.

Os principais insumos do projeto são:

- imagens Sentinel-2 para separação água/terra por MNDWI;
- imagens VIIRS/Black Marble ou camadas equivalentes para luz noturna;
- imagens intermediárias do próprio projeto, como máscaras de água e gradientes de exposição;
- pesos de fauna derivados de OBIS com fallback AquaMaps;
- camada de produtividade primária, baseada em clorofila-a quando disponível ou em fallback local reprodutível;
- catálogo de unidades de conservação em CSV, com suporte a GeoJSON externo.




Figura 1: Comparacao visual entre as tres cidades usando gradiente suavizado de exposicao luminosa sobre agua. A figura contextualiza a diferenca espacial entre baias, orlas urbanizadas e area portuaria.

2.3 Preparacao e pre-processamento

O primeiro passo foi separar agua e terra. O script `water_land_separation.py` gera visualizacoes MNDWI e mascaras binarias. A agua e representada em verde/azul na mascara, enquanto pixels fora da agua sao tratados como fundo.




Figura 2: Mascaras de agua usadas como base espacial para restringir a analise aos ambientes aquaticos. Essa etapa evita interpretar luz sobre area urbana como exposicao direta da agua.

Em seguida, os scripts de exposicao luminosa, comparacao entre cidades e suavizacao constroem mapas de luz sobre agua e comparacoes visuais. A suavizacao reduz bordas artificiais de celulas de satellite, deixando a interpretacao cartografica mais adequada para o relatorio.

2.4 Modelo e arquitetura

A arquitetura adotada e um pipeline em camadas, nao uma rede neural. A Figura 3 resume o fluxo implementado. Cada etapa produz arquivos intermediarios verificaveis, o que facilita depuracao, reprodutibilidade e explicacao das decisoes.




Figura 3: Arquitetura geral do pipeline. O modelo substitui treinamento supervisionado por classificacao deterministica baseada em camadas espaciais e regras transparentes.

O codigo principal esta em `ecological_risk_analysis.py`. Um trecho importante e a leitura da mascara de agua:

```
arr = np.asarray(image, dtype=np.uint8)
return (arr[:, :, 1] > 80) & (arr[:, :, 2] > 80) & (arr[:, :, 0] < 100)
```

Essa regra identifica pixels de agua na mascara RGB gerada previamente. A decisao de trabalhar sobre a mascara evita que predios, ruas e areas terrestres influenciem diretamente o calculo de risco aquatico.

Outro trecho central e a estimativa de luz relativa no fundo:

```
kd_proxy = 0.35 + 0.55 * shallow_factor + 0.10 * (1.0 - light)
bottom_light = light * np.exp(-1.65 * kd_proxy * depth_proxy)
```

Como nao havia batimetria GEBCO nem coeficiente optico real para todos os recortes, a profundidade e a atenuacao foram aproximadas a partir da distancia morfologica da costa. A aproximacao e documentada como proxy, nao como medida oceanografica.

2.5 Treinamento, calibracao, classificacao e testes

Nao houve treinamento supervisionado de rede neural, pois nao existia uma base rotulada com classes biologicas ou pixels anotados. Em vez disso, o projeto realizou calibracao por regras e validacao visual. Os parametros principais foram:

- limiares RGB para reconhecer a mascara de agua;
- normalizacao visual da camada de luz;
- buffers de 0-1 km, 1-5 km, 5-10 km e 10-30 km;
- limiar de alto risco igual a 0,55 no indice normalizado;

- pesos de sensibilidade de fauna por grupo biologico.

A classificacao final ocorre em duas dimensoes. Primeiro, cada pixel aquatico e associado a uma classe de distancia da costa. Depois, o valor continuo de risco e calculado. A partir dele, as metricas por buffer sao agregadas no arquivo CSV de resultados do indice ecologico.




Figura 4: Comparacao do indice ecologico relativo. As areas claras indicam maior coincidencia entre luz artificial, ambiente aquatico e proxies de sensibilidade ecologica.

Os testes realizados incluíram compilacao dos scripts Python, execucao completa do pipeline, verificacao de imagens nao vazias e conferencias no CSV de metricas. No estado final, foram gerados 22 PNGs em `EcologicalRiskImages`, sem imagens vazias, tres arrays de produtividade e 10 linhas de metricas para as cidades e buffers analisados.

2.6 Camadas ambientais e unidades de conservacao

Para fortalecer a interpretacao ecologica, a Prioridade 3 incluiu duas novas fontes. A primeira e a produtividade primaria. O script `fetch_chlorophyll_data.py` tenta obter clorofila-a em servidores ERDDAP/NOAA. Quando a rede ou o dado nao esta disponivel, o script gera uma camada local reprodutivel, derivada da mascara de agua e da proximidade da costa. Essa decisao garante que o pipeline continue executavel e que a origem da camada fique documentada em `chlorophyll_sources.csv`.

A segunda fonte e a sobreposicao com unidades de conservacao. O modulo de sobreposicao carrega um catalogo CSV local na pasta de dados ambientais. Se um GeoJSON externo for colocado na mesma pasta, por exemplo com limites do CNUC/MMA, ele tem prioridade sobre o CSV. Assim, o trabalho permanece funcional sem internet, mas ja esta preparado para limites vetoriais oficiais.

3 Resultados e Discussao

A Tabela 1 apresenta um recorte das metricas finais. Os resultados indicam que o maior risco medio ocorre no buffer de 0–1 km, pois esse intervalo concentra agua costeira rasa, maior influencia urbana e maior intensidade luminosa relativa.




Figura 5: Exemplo de camadas intermediárias para Florianópolis. Elas mostram como o índice final resulta da combinação entre produtividade, habitat sensível e luz que permanece relevante em águas rasas.




Figura 6: Sobreposição do risco relativo com unidades de conservação catalogadas. A figura ajuda a discutir onde áreas de risco estimado coincidem com regiões de interesse ambiental.

Balneário Camboriu apresentou o maior risco médio no buffer de 0–1 km, possivelmente pela forte concentração de iluminação na orla urbanizada. Florianópolis apresentou a maior área aquática analisada nesse mesmo buffer, associada a baías e ao estreito central. Itajaí apresentou concentração relevante próxima ao canal e a área portuária. Em todos os casos, a área classificada como alto risco ficou concentrada no primeiro buffer, enquanto os buffers mais distantes apresentaram risco muito baixo.

As figuras mostram que a interpretação visual é parte essencial do resultado. As máscaras de água garantem que a análise não confunda luz urbana com exposição sobre ambientes aquáticos. Os mapas de produtividade e habitat contextualizam que a camada final não é apenas uma imagem de brilho. A sobreposição com unidades de conservação ajuda a transformar o mapa em uma discussão ambiental, conectando o resultado com áreas de gestão e proteção.

Tabela 1: Metricas principais por cidade e buffer.

Cidade	Buffer	Agua km ²	Luz media	Risco medio	Alto risco km ²
Florianopolis	0–1 km	542,25	0,062	0,048	9,10
Florianopolis	1–5 km	709,36	0,014	0,006	0,00
Florianopolis	5–10 km	65,04	0,007	0,001	0,00
Baln. Camboriu	0–1 km	357,67	0,087	0,066	12,94
Baln. Camboriu	1–5 km	653,59	0,014	0,006	0,00
Baln. Camboriu	5–10 km	201,16	0,006	0,001	0,00
Baln. Camboriu	10–30 km	10,59	0,005	0,000	0,00
Itajai	0–1 km	481,98	0,062	0,038	10,48
Itajai	1–5 km	478,09	0,015	0,005	0,00
Itajai	5–10 km	147,11	0,007	0,001	0,00

4 Conclusões

O trabalho construiu um pipeline completo de processamento de imagem para avaliar poluicao luminosa costeira e risco ecologico relativo em tres cidades de Santa Catarina. A solucao gerou mascaras, gradientes, buffers, metricas tabulares, mapas intermediarios, indice final e sobreposicoes com unidades de conservacao. A principal decisao tecnica foi substituir uma rede neural supervisionada por um classificador deterministico e explicavel, pois nao havia base rotulada suficiente para treinamento robusto.

Os resultados indicam que as regioes mais proximas da costa concentram maior risco relativo. Balneario Camboriu se destaca pelo maior risco medio no buffer imediato, Florianopolis pela extensao de agua exposta e Itajai pela concentracao em torno da area portuaria e canal do Itajai-Acu. Esses achados sao coerentes com a configuracao urbana e costeira das cidades, mas devem ser lidos como indicios relativos, nao como prova de impacto biologico direto.

As principais dificuldades foram a falta de rotulos para treinamento supervisionado, a ausencia de batimetria e coeficientes opticos reais no recorte local, a dependencia de servicos externos para clorofila-a e OBIS, e a necessidade de representar limites de unidades de conservacao sem um GeoJSON oficial disponivel localmente. Para contornar esses pontos, foram usados fallbacks documentados e reproduziveis, sempre preservando a transparencia metodologica.

Como trabalhos futuros, recomenda-se integrar batimetria GEBCO, coeficientes opticos do Bio-ORACLE ou OceanColor, limites vetoriais oficiais do CNUC/MMA e series temporais VIIRS. Outra melhoria relevante seria montar uma base rotulada por especialistas para permitir comparacao entre o pipeline deterministico atual e modelos supervisionados de aprendizado de maquina.

Referências

- [1] NOAA. VIIRS Day/Night Band and night lights products. Disponivel em: <https://www.noaa.gov/>.
- [2] European Space Agency. Sentinel-2 mission and multispectral imagery. Disponivel em: <https://sentinel.esa.int/>.

- [3] Ocean Biodiversity Information System. OBIS API and occurrence data. Disponivel em: <https://obis.org/>.
- [4] Brasil. Lei no 9.985, de 18 de julho de 2000. Institui o Sistema Nacional de Unidades de Conservacao da Natureza.
- [5] Xu, H. Modification of normalised difference water index (NDWI) to enhance open water features in remotely sensed imagery. *International Journal of Remote Sensing*, 2006.